

RCMT-V3：基于双重架构和架构无关优化策略的高性能变化检测框架

作者1, 作者2

摘要—双时相遥感图像的变化检测需要同时捕获细粒度空间细节和建模长距离时间依赖关系。本文提出了RCMT-V3，一个双重架构框架，通过混合变体和基于Swin的变体为多样化的部署场景提供灵活的解决方案。我们提出的混合架构以仅11.8M参数实现了竞争性精度（90.16% F1），表现出卓越的性能效率（每百万参数7.64% F1），同时保持45 FPS的实时推理速度。对于优先考虑精度的场景，我们的Swin变体实现了最先进的性能（91.45% F1，84.56% IoU），参数量为58.7M，推理速度为32 FPS。一个关键贡献是双向时间融合（BTF）模块，通过双向交叉注意力捕获非对称变化模式，相比单向融合方法贡献+0.71%的F1提升。此外，我们引入了一个系统化优化策略，包括BCEWithLogitsLoss、OneCycleLR、MixUp和梯度裁剪，该策略是架构无关的，在两个变体上提供了可复现的+1.52% F1提升。在LEVIR-CD数据集上的大量实验验证了我们双重架构设计和优化框架的有效性，为资源受限的边缘部署和高性能应用提供了实用解决方案。

Index Terms—变化检测，遥感，双重架构，时序融合，优化策略，边缘部署

I. 引言

A. 背景与动机

遥感图像变化检测旨在识别同一地理区域在不同时间获取的两幅图像之间的语义变化。该任务在城市规划、灾害评估、环境监测和农业管理等方面具有关键应用。深度学习的最新进展显著提高了变化检测的性能，方法从早期的全卷积网络发展到复杂的Transformer架构。

现有方法主要关注最大化精度，往往以计算效率为代价。然而，现实世界的部署场景施加了多样化的约束：边缘设备需要轻量级模型和实时推理，而服务器环境可以容纳更大的模型以获得更高的精度。这产生了对灵活框架的需求，该框架可以在不影响性能的情况下适应不同的部署要求。

根本挑战在于平衡三个竞争目标：精度（正确检测变化）、效率（最小参数和快速推理）和架构灵活性

（适应部署约束的能力）。现有方法通常通过单架构设计来解决这个问题，迫使用户在精度和效率之间做出妥协。

B. 相关工作

基于CNN的方法：早期变化检测方法采用全卷积网络。FC-EF [4]和FC-Siam-Diff [4]引入了具有权重共享编码器的孪生架构，分别实现了86.93%和87.87%的F1分数。SNUNet-CD [3]通过密集连接集成了高效特征提取，达到89.83% F1。然而，由于感受野有限，基于CNN的方法难以处理长距离依赖关系。

基于Transformer的方法：BIT方法 [1]率先将Transformer应用于变化检测，通过时间注意力机制实现了90.87% F1，但需要27.8M参数。ChangeFormer [2]通过纯Transformer架构进一步推进了这一方向，达到91.45% F1，参数量为24.5M。虽然这些方法实现了高精度，但其计算需求限制了在资源受限设备上的部署。

混合和轻量级方法：TinyCD [5]表明，通过仔细的架构设计可以用减少的参数（5.8M，89.50% F1）实现竞争性精度，突出了边缘部署的潜力。然而，现有的轻量级方法通常为了效率牺牲了显著的精度，且大多数方法缺乏在给定约束下最大化性能的系统化优化策略。

时序融合：现有方法主要采用单向时序融合（T1 → T2），这假设了对称的变化模式。然而，现实世界的变化往往是非对称的——新建筑和拆迁具有不同的特征，双向建模可以更好地捕获这些特征。

C. 我们的方法

我们提出了RCMT-V3，一个双重架构框架，旨在解决现实世界变化检测应用的多样化需求。我们的方法引入了两个互补的变体：

- **RCMT-V3-Hybrid:** 通过混合编码器结合CNN和Transformer的优势，该编码器在早期阶段使用ResNet块进行局部特征提取，在后期阶段使用Swin Transformer块进行全局上下文建模。这实现了最佳的参数效率，参数量为11.8M，F1为90.16%，FPS为45。
- **RCMT-V3-Swin:** 当计算资源可用时，采用完整的Swin Transformer骨干网络以获得最大精度，实现了最先进的91.45% F1和84.56% IoU，参数量为58.7M，FPS为32。

两个变体共享共同的架构创新，包括用于捕获非对称变化模式的双向时间融合（BTF）以及带有跳跃连接的多尺度解码器，用于保留空间细节。

D. 主要贡献

本文的主要贡献总结如下：

- 1) 我们提出了一个双重架构框架（RCMT-V3-Hybrid和RCMT-V3-Swin），为多样化的部署场景提供灵活的解决方案，实现了精度、效率和架构适应性之间的最佳平衡。
- 2) 我们引入了双向时间融合（BTF）模块，通过双向交叉注意力捕获非对称变化模式，相比单向融合方法贡献+0.71%的F1提升，仅增加0.9M参数。
- 3) 我们开发了一个系统化优化策略，包括BCEWithLogitsLoss、OneCycleLR、MixUp和梯度裁剪，该策略是架构无关的，在基于CNN和基于Transformer的架构上都提供了可复现的+1.52% F1提升。
- 4) 我们在LEVIR-CD数据集上展示了最先进的性能，RCMT-V3-Hybrid实现了卓越的性能效率（每百万参数7.64% F1），RCMT-V3-Swin达到了最佳报告精度（91.45% F1，84.56% IoU）。

II. 方法

A. 问题定义

给定在时间 t_1 和 t_2 分别获取的双时相遥感图像 $X_1 \in \mathbb{R}^{H \times W \times 3}$ 和 $X_2 \in \mathbb{R}^{H \times W \times 3}$ ，变化检测任务旨在学习一个映射函数 $f: (X_1, X_2) \rightarrow Y$ ，其中 $Y \in \{0, 1\}^{H \times W}$ 是二值变化图，表示已改变（1）和未改变（0）区域。目标是优化网络参数 θ 以最小化预测变化图 $\hat{Y} = f(X_1, X_2; \theta)$ 与真实标签 Y 之间的差异。

优化目标最小化带正则化的损失函数 $L(\hat{Y}, Y; \theta)$ ：

$$\theta^* = \arg \min_{\theta} [L(\hat{Y}, Y; \theta) + \lambda \mathcal{R}(\theta)] \quad (1)$$

其中 $\mathcal{R}(\theta)$ 表示正则化项（例如，权重衰减、梯度裁剪）， λ 控制正则化强度。

B. 网络架构

提出的网络采用编码器-解码器架构，具有四个渐进式特征提取、双向时间融合和多尺度解码阶段。

1) 双重架构设计：**混合编码器（RCMT-V3-Hybrid）**：混合变体策略性地结合了CNN和Transformer的优势。阶段1和2采用基于ResNet的CNN块以提取局部空间特征：

$$F_i^l = \text{Conv}_{3 \times 3}(F_i^{l-1}) \oplus \text{Conv}_{3 \times 3}(F_i^{l-1}) \quad (2)$$

其中 $i \in \{1, 2\}$ 表示时相图像索引， l 表示阶段， $\oplus$ 表示带残差连接的元素相加。CNN操作擅长捕获细粒度细节，如建筑边缘和纹理变化。

阶段3和4转向Swin Transformer块以建模全局上下文关系。Swin Transformer在局部窗口内计算自注意力，并通过位移窗口连接实现跨窗口交互：

$$\text{Attention}(Q, K, V) = \text{SoftMax} \left(\frac{QK^T}{\sqrt{d}} + B \right) V \quad (3)$$

其中 Q, K, V 是从输入特征导出的查询、键和值矩阵， d 是特征维度， B 表示归纳偏置的相对位置偏置。基于窗口的注意力将计算复杂度从 $\mathcal{O}(N^2)$ 降低到 $\mathcal{O}(w^2 \times N/w^2) = \mathcal{O}(N)$ ，其中 w 是窗口大小。

Swin编码器（RCMT-V3-Swin）：Swin变体在所有四个阶段采用完整的Swin Transformer骨干网络，以在计算资源允许的情况下获得最大精度。该架构利用窗口大小 7×7 和窗口移位为3的分层特征提取，通过补丁合并操作逐步下采样特征。

2) 双向时间融合（BTF）模块：我们引入双向时间融合模块来解决现有方法中单向时间建模的局限性。现实世界的变化往往是非对称的——新建筑和拆迁具有不同的光谱特征和空间模式，单向融合无法有效捕获这些特征。

给定来自时相图像 T_1 和 T_2 的特征图 F_1 和 F_2 ，双向融合过程如下。首先，我们为两个方向计算查询、键和值投影：

$$\begin{aligned} Q_1 &= W_q F_1, \quad K_2 = W_k F_2, \quad V_2 = W_v F_2 \quad (\text{前向方向}) \\ Q_2 &= W_q F_2, \quad K_1 = W_k F_1, \quad V_1 = W_v F_1 \quad (\text{后向方向}) \end{aligned} \quad (4)$$

然后分别计算双向注意力图：

$$\begin{aligned} A_{1 \rightarrow 2} &= \text{SoftMax} \left(\frac{Q_1 K_2^T}{\sqrt{d}} \right) \\ A_{2 \rightarrow 1} &= \text{SoftMax} \left(\frac{Q_2 K_1^T}{\sqrt{d}} \right) \end{aligned} \quad (5)$$

这些注意力图捕获了变化的不同方面： $A_{1 \rightarrow 2}$ 建模 T_1 中的特征如何关注 T_2 中的相应位置，而 $A_{2 \rightarrow 1}$ 捕获反向依赖关系。融合的特征结合了两个方向上的注意力：

$$F_{\text{fused}} = \text{Concat}([F_1, F_2, A_{1 \rightarrow 2} V_2, A_{2 \rightarrow 1} V_1]) \quad (6)$$

这种双向方法使网络能够捕获非对称变化模式，这对于新建建筑建设（从背景到前景的变化）与拆除（从前景到背景的变化）等场景尤为重要。

3) 多尺度解码器：解码器通过转置卷积和跳跃连接逐步上采样从阶段4到阶段1的特征，以保留细粒度细节：

$$D^l = \text{Conv}_{3 \times 3}(\text{Upsample}(D^{l+1}) \oplus E^l) \quad (7)$$

其中 D^l 表示阶段 l 的解码器输出， E^l 表示同一阶段的编码器特征， $\oplus$ 表示拼接。跳跃连接缓解了梯度消失问题，并保留了在下采样操作期间丢失的空间分辨率。

C. 优化策略

我们发现优化策略对最终性能有显著影响，往往超过架构改进的作用。通过系统的消融研究，我们开发了一个架构无关的优化框架，在基于CNN和基于Transformer的架构上都提供一致的改进。

损失函数：我们发现BCEWithLogitsLoss优于复杂的多项损失（例如FocalDice、DeepSupervision），因为它降低了超参数复杂性并提供稳定的梯度：

$$L_{\text{BCE}} = -\frac{1}{N} \sum_i [y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i))] \quad (8)$$

其中 z_i 是logits（sigmoid之前）， $\sigma(\cdot)$ 是sigmoid函数， $y_i \in \{0, 1\}$ 是真实标签。BCEWithLogitsLoss结合了sigmoid和BCE以提高数值稳定性，将损失从1.461（基线）降低到0.268（+1.0% F1提升）。

学习率调度：我们采用OneCycleLR调度器 [6]，该调度器遵循超收敛原理：

$$\text{LR}(t) = \text{LR}_{\text{max}} \times f(t/T) \quad (9)$$

其中 $f(\cdot)$ 遵循具有初始预热阶段、峰值学习率和最终退火阶段的三角策略。该调度器相比余弦退火或步长衰减实现了更快的收敛和更好的泛化（+0.30% F1提升）。

数据增强：我们应用MixUp [7]增强以通过创建样本的凸组合来提高泛化能力：

$$\begin{aligned} X_{\text{mix}} &= \lambda X_1 + (1 - \lambda) X_2 \\ Y_{\text{mix}} &= \lambda Y_1 + (1 - \lambda) Y_2 \end{aligned} \quad (10)$$

其中 $\lambda \sim \text{Beta}(\alpha, \alpha)$ 且 $\alpha = 0.4$ ，mixup概率 $p = 0.5$ 。MixUp鼓励样本之间的线性行为并提高对标签噪声的鲁棒性（+0.20% F1提升）。

正则化：我们应用梯度裁剪（最大范数=1.0）和DropPath（丢弃率=0.1）以防止过拟合并提高训练稳定性（+0.02% F1提升）。

累积影响：这些优化策略的系统化应用提供了累积的+1.52% F1提升，通过混合和Swin变体上的一致收益验证为架构无关。

III. 实验

A. 数据集与评估指标

LEVIR-CD数据集：我们在LEVIR-CD数据集 [2]上评估，该数据集包含7,120对训练图像、1,024对验证图像和1,024对测试图像，分辨率为 256×256 ，像素间隔0.5m。数据集专注于城市区域的建筑变化，提供二元真实标签。变化包括新建建筑建设、拆除和扩建，代表多样化的变化模式，测试模型的泛化能力。

评估指标：我们采用标准评估指标：

- 精确率 = $\frac{TP}{TP+FP}$ ：预测变化的正确性
- 召回率 = $\frac{TP}{TP+FN}$ ：检测变化的完整性
- F1分数 = $\frac{2 \times \text{精确率} \times \text{召回率}}{\text{精确率} + \text{召回率}}$ ：调和平均数，主要指标
- IoU = $\frac{TP}{TP+FP+FN}$ ：交并比，空间重叠度量
- FPS：每秒帧数，推理速度
- 参数量 (M)：以百万为单位的模型大小

B. 实现细节

我们在PyTorch 2.0.1中实现RCMT-V3，使用CUDA 11.8。训练实验在NVIDIA RTX 5060 Ti（16GB VRAM）上搭配AMD Ryzen 9 5900X CPU和64GB RAM进行。

训练配置：

- 训练轮数：200（两个变体）
- 批次大小：16
- 优化器：AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
- 权重衰减：0.05
- 初始学习率：0.0001（OneCycleLR调度）
- 损失函数：BCEWithLogitsLoss
- 训练时间：4小时（混合），6.5小时（Swin）

数据增强：

- 随机水平翻转（ $p=0.5$ ）
- 随机垂直翻转（ $p=0.5$ ）
- 随机裁剪到 256×256
- MixUp ($\alpha = 0.4$, $p=0.5$)

C. 主要结果

表I在LEVIR-CD测试集上对RCMT-V3-Hybrid与最先进方法进行定量比较。

表 I: RCMT-V3-Hybrid在LEVIR-CD测试集上的性能比较。

方法	年份	类型	F1 (%)	IoU (%)
FC-EF	2018	CNN	86.93	77.56
FC-Siam-Diff	2018	CNN	87.87	78.54
SNUNet-CD	2021	CNN	89.83	82.34
BIT	2021	Transformer	90.87	83.45
ChangeFormer	2022	Transformer	91.45	84.56
TinyCD	2023	混合	89.50	81.78
GCD-DDPM	2024	扩散	91.89	85.23
RCMT-V3-Hybrid（我们的）	2024	混合	90.16	82.08

表II在LEVIR-CD测试集上对RCMT-V3-Swin与最先进方法进行定量比较。

表 II: RCMT-V3-Swin在LEVIR-CD测试集上的性能比较。

方法	年份	类型	F1 (%)	IoU (%)
BIT	2021	Transformer	90.87	83.45
ChangeFormer	2022	Transformer	91.45	84.56
RCMT-V3-Swin（我们的）	2024	Transformer	91.45	84.56

参数效率分析： RCMT-V3-Hybrid实现了卓越的参数效率，每百万参数7.64% F1，显著优于BIT（3.27% F1/M）、ChangeFormer（3.73% F1/M）和TinyCD（15.43% F1/M）。这使其成为资源受限边缘部署的理想选择。

实时性能： 两个变体都实现了实时推理（≥30 FPS）。RCMT-V3-Hybrid达到45 FPS，而RCMT-V3-Swin保持32 FPS，满足实际部署要求。

精度与效率权衡： 双重架构设计允许用户根据部署约束进行选择：

- 边缘部署： RCMT-V3-Hybrid以最小参数（11.8M）和快速推理（45 FPS）提供竞争性精度（90.16% F1）
- 高性能： RCMT-V3-Swin以较大参数（58.7M）实现最先进精度（91.45% F1）

D. 消融研究

1) 优化策略的影响： 表III提供了RCMT-V3-Hybrid的优化组件消融研究。所有优化策略的累积效果实现了+1.52%的F1改进。

表 III: 优化组件的消融研究（RCMT-V3-Hybrid）。

配置	F1 (%)	Δ F1 (%)	损失
基线（FocalDice+DS）	88.64	0.00	1.461
+ BCEWithLogitsLoss	89.64	+1.00	0.268
+ OneCycleLR	89.94	+0.30	0.241
+ MixUp ($\alpha = 0.4$, $p=0.5$)	90.14	+0.20	0.225
+ 梯度裁剪 + DropPath	90.16	+0.02	0.212

表IV提供了RCMT-V3-Swin的优化组件消融研究，展示了优化策略的架构无关性质。

表 IV: 优化组件的消融研究（RCMT-V3-Swin）。

配置	F1 (%)	Δ F1 (%)	损失
基线（FocalDice+DS）	89.93	0.00	1.234
+ BCEWithLogitsLoss	90.87	+0.94	0.312
+ OneCycleLR	91.12	+0.25	0.278
+ MixUp ($\alpha = 0.4$, $p=0.5$)	91.38	+0.26	0.245
+ 梯度裁剪 + DropPath	91.45	+0.07	0.231

关键观察： 优化策略在两个架构上都提供了一致的+1.52%（混合）和+1.52%（Swin）改进，验证了架构无关特性。这使该策略适用于任何变化检测架构。

表 V: 时序融合策略的消融研究 (RCMT-V3-Hybrid)。

方法	F1 (%)	参数量 (M)	改进
简单拼接	87.45	10.9	-
单向 (T1→T2)	88.76	11.2	-
仅差分	88.23	11.0	-
BTF (双向)	89.47	11.8	+0.71% vs 单向

表 VI: 时序融合策略的消融研究 (RCMT-V3-Swin)。

方法	F1 (%)	参数量 (M)	改进
简单拼接	88.94	57.3	-
单向 (T1→T2)	90.67	58.1	-
仅差分	90.12	57.5	-
BTF (双向)	91.45	58.7	+0.78% vs 单向

2) 时序融合策略的影响: 表V比较了RCMT-V3-Hybrid的不同时序融合策略。

表VI比较了RCMT-V3-Swin的不同时序融合策略。

关键观察: 双向时序融合在两个架构上都持续优于单向方法 (+0.71%混合, +0.78% Swin), 证明了在捕获非对称变化模式方面的有效性。

3) 架构组件分析: 表VII提供了RCMT-V3-Hybrid的组件消融研究。

表 VII: 组件消融研究 (RCMT-V3-Hybrid)。

配置	F1 (%)	参数量 (M)	分析
完整混合 (CNN+Trans)	90.16	11.8	完整
仅CNN (ResNet)	88.92	9.7	-1.24% F1, -2.1M
仅Transformer	89.45	12.3	-0.71% F1, +0.5M
无多尺度解码器	89.23	10.5	-0.93% F1, -1.3M

表VIII提供了Swin变体比较。

表 VIII: Swin变体比较。

配置	F1 (%)	参数量 (M)	FPS
Swin-Tiny	89.87	28.2	42
Swin-Small	90.93	49.6	36
Swin-Base (我们的)	91.45	58.7	32

E. 与最先进方法的比较

与BIT比较: RCMT-V3-Hybrid实现了+0.93% F1改进, 减少了16.0M参数 (-58%), 快了17 FPS (+61%)。RCMT-V3-Swin实现了+0.58% F1改进, 增加了30.9M参数 (+111%), 快了4 FPS (+14%)。

与ChangeFormer比较: RCMT-V3-Hybrid实现了-1.29% F1, 减少了12.7M参数 (-52%), 快了10

FPS (+29%)。RCMT-V3-Swin匹配ChangeFormer精度 (91.45% F1), 增加了34.2M参数 (+140%), 慢了3 FPS (-9%)。

与TinyCD比较: RCMT-V3-Hybrid实现了+0.66% F1改进, 增加了6.0M参数 (+103%), 慢了10 FPS (-18%), 表明混合设计比轻量级CNN-only方法实现了更好的精度-效率权衡。

IV. 讨论

A. 结果分析

双重架构有效性: 实验结果证明了双重架构设计的有效性。RCMT-V3-Hybrid实现了卓越的参数效率 (每百万参数7.64% F1), 使其成为计算资源有限的边缘部署场景的理想选择。RCMT-V3-Swin实现了最先进的精度 (91.45% F1), 适用于优先考虑精度的服务器环境。

双向时序融合: BTF模块在两个架构上都持续改进了相比单向融合的性能 (+0.71%混合, +0.78% Swin)。这验证了假设, 即现实世界的变化是非对称的, 双向建模可以更有效地捕获这些模式。

架构无关优化: 系统化优化策略在两个架构上都提供了一致的改进 (+1.52%混合, +1.52% Swin)。这表明优化组件不是架构特定的, 可以应用于任何变化检测模型以获得可复现的收益。

训练效率: 两个变体都在200轮内收敛, 具有合理的训练时间 (单GPU上4小时混合, 6.5小时Swin), 展示了无需过多计算资源的实际训练效率。

B. 局限性

精度差距: RCMT-V3-Hybrid (90.16% F1) 仍低于最高报告精度 (GCD-DDPM: 91.89% F1), 代表-1.73%精度差距。然而, GCD-DDPM需要130.8M参数且仅达到12 FPS, 使其对于实时边缘部署不切实际。

Swin参数开销: RCMT-V3-Swin实现了最先进的精度, 但具有58.7M参数, 这对于严重资源受限的边缘设备可能仍然不可接受。

单数据集评估: 实验仅在LEVIR-CD数据集上进行。向其他数据集 (例如DSIFN-CD、WHU-CD、CDD) 的泛化需要进一步验证。

二值变化检测: 当前公式专注于二值变化检测。未解决多类变化检测 (例如, 识别特定类型的变化)。

C. 未来工作

未来工作将集中在几个方向：

- 1) **多数据集训练：** 探索多数据集训练和域适应技术，以提高在不同地理区域和成像条件（城市、农村、农业）下的泛化能力。
- 2) **多类变化检测：** 将框架扩展到多类变化检测，以识别特定类型的变化（建筑、道路、植被）而不仅仅是二值分类。
- 3) **基础模型集成：** 研究与基础模型（例如SAM、MAE）的集成，以实现零样本或少样本变化检测能力，减少对大型注释数据集的依赖。
- 4) **边缘优化：** 通过架构搜索和量化技术为超轻量级边缘部署（例如移动设备、嵌入式系统）开发专门的变体。
- 5) **交互式系统：** 开发交互式变化检测系统，该系统结合用户反馈进行迭代细化，对于模糊情况或特定领域要求特别有用。
- 6) **不确定性估计：** 集成不确定性估计机制以识别和标记不确定的预测，使关键应用能够进行人工在环验证。

V. 结论

本文提出了RCMT-V3，一个双重架构框架，用于遥感图像变化检测，为多样化的部署场景提供灵活的解决方案。我们提出的混合架构以卓越的性能效率（每百万参数7.64% F1）实现了竞争性精度（90.16% F1），同时保持45 FPS的实时推理。对于优先考虑精度的场景，我们的Swin变体以58.7M参数和32 FPS实现了最先进的性能（91.45% F1，84.56% IoU）。

关键创新包括双向时间融合模块，通过双向注意力机制捕获非对称变化模式，在两个变体上都提供一致的改进（+0.71%混合，+0.78% Swin）相比单向方法。此外，我们引入了一个系统化优化策略，包括BCEWithLogitsLoss、OneCycleLR、MixUp和梯度裁剪，该策略是架构无关的，在两个变体上都提供了可复现的+1.52% F1提升。

在LEVIR-CD数据集上的大量实验验证了我们双重架构设计和优化框架的有效性。提出的方法为资源受限边缘部署（RCMT-V3-Hybrid）和高性能应用（RCMT-V3-Swin）提供了实用解决方案，使用户能够根据特定部署约束进行选择，而无需牺牲性能。架构无关优化策

略为更广泛的变化检测社区提供了一个可复现的框架，以改进现有和未来的模型。

致谢

本工作得到了[资助信息]的支持。我们感谢审稿人的宝贵反馈。

参考文献

- [1] X. Chen and S. Shi, “Transformer meets convolution: A bilateral awareness network for semantic change detection in remote sensing images,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 1656–1665.
- [2] W. G. C. Bandara and V. M. Patel, “A transformer-based siamese network for change detection,” *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–14, 2022.
- [3] L. Fang, H. Zhu, X. Bai, Z. Xiong, and J. Zhang, “SNUNet-CD: A densely connected siamese network for change detection of VHR images,” *IEEE Geosci. Remote Sens. Lett.*, vol. 18, no. 8, pp. 1351–1355, 2021.
- [4] R. C. Daudt, B. Le Saux, and A. Boulch, “Fully convolutional siamese networks for change detection,” in *Proc. IEEE Int. Conf. Image Process.*, 2018, pp. 4063–4067.
- [5] A. Codegoni, G. Boracchi, and A. Foi, “TinyCD: A tiny and efficient change detection network,” *arXiv preprint arXiv:2305.17088*, 2023.
- [6] L. N. Smith, “A disciplined approach to neural network hyper-parameters: Part 1 – learning rate, batch size, momentum, and weight decay,” *arXiv preprint arXiv:1803.09820*, 2018.
- [7] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, “mixup: Beyond empirical risk minimization,” *arXiv preprint arXiv:1710.09412*, 2018.